

## Projet 5 : La Méthode EM « Expectation-Maximization »

Habituellement, pour estimer un paramètre on effectue la méthode du maximum de vraisemblance. Cependant elle peut être fastidieuse à mettre en œuvre notamment dans les problèmes de données manquantes. Pour pallier à ce problème, M. Dempster a mis en place une méthode appelée méthode « Expectation-Maximisation » ou plus communément connue sous le nom de la méthode EM. Cette méthode est une méthode d'estimation paramétrique via la vraisemblance d'un modèle probabiliste grâce à un algorithme itératif. Cet algorithme permet de pallier au problème de données manquantes et chaque itération se déroule en 2 étapes : l'étape E : « Expectation » et l'étape M : « Maximisation ».

Etape E :

On note  $X^c := (X, X^m)$  le vecteur complet, dont  $X$  désigne le vecteur des variables observées et  $X^m$  le vecteur des données manquantes. Comme on dispose de données inconnues, la log-vraisemblance des « données complètes » va s'écrire  $\mathbb{E}_{X^m|X, \theta} [\log(\mathbb{P}(X, x^m|p))]$  ou  $\log(\mathbb{P}(X, x^m|p))$  est la log-vraisemblance et  $p$  le paramètre à estimer.

Etape M :

On va maximiser la log-vraisemblance et ainsi obtenir une nouvelle estimation de  $p$ .

Cette méthode est très souvent utilisée dû à sa simplicité et sa robustesse. Elle est notamment utilisée dans plusieurs domaines tels que l'imagerie médicale ou bien encore la classification de données.

### Question 1.1

**Montrons que  $f(x^m|x)$  est la densité d'une Gaussienne sur  $\mathbb{R}^{d_2}$  de moyenne  $\mu_2 + (\Sigma_{12})^T \Sigma_{11}^{-1}(x - \mu_1)$  et de matrice de covariance  $\Sigma_{22} - \Sigma_{12}^T \Sigma_{11}^{-1} \Sigma_{12}$ .**

$$\text{Posons } Z = \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} = A(X^c - \mu) \text{ où } A = \begin{pmatrix} I_{d_1} & 0 \\ -(\Sigma_{12})^T \Sigma_{11}^{-1} & I_{d_2} \end{pmatrix}$$

$$\text{Donc } (X^c - \mu) = A^{-1}Z = \begin{pmatrix} I_{d_1} & 0 \\ (\Sigma_{12})^T \Sigma_{11}^{-1} & I_{d_2} \end{pmatrix} \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} = \begin{pmatrix} I_{d_1} Z_1 \\ (\Sigma_{12})^T \Sigma_{11}^{-1} Z_1 + I_{d_2} Z_2 \end{pmatrix}$$

$$\text{On pose } x = I_{d_1} Z_1 \text{ et } y = (\Sigma_{12})^T \Sigma_{11}^{-1} Z_1 + I_{d_2} Z_2$$

$$\begin{cases} Z_1 = x I_{d_1} \\ y = (\Sigma_{12})^T \Sigma_{11}^{-1} Z_1 + I_{d_2} Z_2 \end{cases} \Rightarrow \begin{cases} Z_1 = x I_{d_1} \\ Z_2 = x I_{d_2} (\Sigma_{12})^T \Sigma_{11}^{-1} I_{d_1} - y I_{d_2} \end{cases} \text{ et } |J| = \begin{vmatrix} I_{d_1} & 0 \\ I_{d_2} (\Sigma_{12})^T \Sigma_{11}^{-1} I_{d_1} & -I_{d_2} \end{vmatrix} = 1$$

Densité de  $Z$  :

$$\begin{aligned} f(Z_1, Z_2) &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(X^c - \mu)^T \Sigma^{-1} (X^c - \mu)} \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(A^{-1}Z)^T \Sigma^{-1} (A^{-1}Z)} \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}Z^T (A^{-1})^T \Sigma^{-1} (A^{-1}Z)} \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}Z^T (A^T)^{-1} \Sigma^{-1} (A^{-1}Z)} \quad (A \text{ est une matrice triangulaire donc } (A^{-1})^T = (A^T)^{-1}) \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}Z^T (A \Sigma A^T)^{-1} Z} \end{aligned}$$

$$\begin{aligned}
A\Sigma A^T &= \begin{pmatrix} I_{d_1} & 0 \\ -(\Sigma_{12})^T \Sigma_{11}^{-1} & I_{d_2} \end{pmatrix} \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{12}^T & \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_{d_1} & -(\Sigma_{12})^T \Sigma_{11}^{-1} \\ 0 & I_{d_2} \end{pmatrix} \\
&= \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ -(\Sigma_{12})^T \Sigma_{11}^{-1} \Sigma_{11} + \Sigma_{12}^T & -(\Sigma_{12})^T \Sigma_{11}^{-1} \Sigma_{12} + \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_{d_1} & -(\Sigma_{12})^T \Sigma_{11}^{-1} \\ 0 & I_{d_2} \end{pmatrix} \\
&= \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ 0 & -(\Sigma_{12})^T \Sigma_{11}^{-1} \Sigma_{12} + \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_{d_1} & -(\Sigma_{11}^{-1})^T \Sigma_{12} \\ 0 & I_{d_2} \end{pmatrix} \\
&= \begin{pmatrix} \Sigma_{11} & -\Sigma_{11} (\Sigma_{11}^{-1})^T \Sigma_{12} + \Sigma_{12} \\ 0 & -(\Sigma_{12})^T \Sigma_{11}^{-1} \Sigma_{12} + \Sigma_{22} \end{pmatrix}
\end{aligned}$$

Comme  $\Sigma_{11}$  est une matrice de covariance, elle est symétrique donc  $\Sigma_{11}^T = \Sigma_{11}$  et on a :

$$-\Sigma_{11} (\Sigma_{11}^{-1})^T \Sigma_{12} + \Sigma_{12} = -\Sigma_{11} (\Sigma_{11}^T)^{-1} \Sigma_{12} + \Sigma_{12} = -\Sigma_{11} (\Sigma_{11})^{-1} \Sigma_{12} + \Sigma_{12} = 0$$

$$\text{Finalement, } A\Sigma A^T = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & b \end{pmatrix} \text{ avec } b = \Sigma_{22} - \Sigma_{12}^T \Sigma_{11}^{-1} \Sigma_{12}$$

$$(A\Sigma A^T)^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} & 0 \\ 0 & b^{-1} \end{pmatrix} \Rightarrow Z^T (A\Sigma A^T)^{-1} Z = Z_1^T \Sigma_{11}^{-1} Z_1 + Z_2^T b^{-1} Z_2 \text{ et } |\Sigma| = |\Sigma_{11}| |b|$$

$$\text{Donc : } g(Z_1, Z_2) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_{11}|^{\frac{1}{2}} |b|^{\frac{1}{2}}} e^{-\frac{1}{2} (Z_1^T \Sigma_{11}^{-1} Z_1 + Z_2^T b^{-1} Z_2)} = \frac{1}{(2\pi)^{d_1/2} |\Sigma_{11}|^{1/2}} e^{-\frac{1}{2} Z_1^T \Sigma_{11}^{-1} Z_1} \times \frac{1}{(2\pi)^{d_2/2} |b|^{1/2}} e^{-\frac{1}{2} Z_2^T b^{-1} Z_2}$$

$$\text{La loi marginale de } Z_1 \text{ est donnée par : } \int_{\mathbb{R}^{d_2}} g(Z_1, Z_2) dz_2 = \frac{1}{(2\pi)^{d_1/2} |\Sigma_{11}|^{1/2}} e^{-\frac{1}{2} Z_1^T \Sigma_{11}^{-1} Z_1}$$

On a donc montré que  $Z_1 \sim N(0, \Sigma_{11})$

$$\Rightarrow (x - \mu_1) \sim N(0, \Sigma_{11})$$

$$\Rightarrow x \sim N(\mu_1, \Sigma_{11})$$

$$f_{Z_2|Z_1} = \frac{f(Z_1, Z_2)}{f_{Z_1}(Z_1)} \sim N(0, \Sigma_{22} - \Sigma_{12}^T \Sigma_{11}^{-1} \Sigma_{12})$$

$$Z_1 \perp\!\!\!\perp Z_2 \text{ donc } Z_2 \sim Z_2|Z_1 \text{ donc } Z_2 = -(\Sigma_{12})^T \Sigma_{11}^{-1} (x - \mu_1) + x^m - \mu_2 \sim N(0, \Sigma_{22} - \Sigma_{12}^T \Sigma_{11}^{-1} \Sigma_{12})$$

$$x^m | x \sim N(\mu_2 + (\Sigma_{12})^T \Sigma_{11}^{-1} (x - \mu_1), \Sigma_{22} - \Sigma_{12}^T \Sigma_{11}^{-1} \Sigma_{12})$$

## Question 1.2

Montrons que  $\log[f_X(x, p)] = Q(p, p^{old}) - H(p, p^{old})$

$$\begin{aligned}
Q(p, p^{old}) - H(p, p^{old}) &= \mathbb{E}[\log f(X^c, p) | X = x, p^{old}] - \mathbb{E}[\log f(X^m | x, p) | X = x, p^{old}] \\
&= \int_{\mathbb{R}^{d_2}} \log[f((x, x^m), p)] f(x^m | x, p^{old}) dx^m - \int_{\mathbb{R}^{d_2}} \log[f(x^m | x, p)] f(x^m | x, p^{old}) dx^m \\
&= \int_{\mathbb{R}^{d_2}} \log\left(\frac{f((x, x^m), p)}{f(x^m | x, p)}\right) f(x^m | x, p^{old}) dx^m \\
&= \int_{\mathbb{R}^{d_2}} \log\left(\frac{f(x^m | x, p) f_X(x, p)}{f(x^m | x, p)}\right) f(x^m | x, p^{old}) dx^m \\
&= \int_{\mathbb{R}^{d_2}} \log[f_X(x, p)] f(x^m | x, p^{old}) dx^m \\
&= \log[f_X(x, p)] \int_{\mathbb{R}^{d_2}} f(x^m | x, p^{old}) dx^m = \log[f_X(x, p)]
\end{aligned}$$

Donc on a bien  $\log[f_X(x, p)] = Q(p, p^{old}) - H(p, p^{old})$

**Montrons que**  $H(p^{old}, p^{old}) - H(p, p^{old}) = - \int_{\mathbb{R}^{d_2}} f(x^m | x, p^{old}) \log \left( \frac{f(x^m | x, p)}{f(x^m | x, p^{old})} \right) dx^m \geq 0$ .

$$\begin{aligned} \mathbb{E}[\log f(X^m | x, p^{old}) | X = x, p^{old}] - \mathbb{E}[\log f(X^m | x, p), X = x, p^{old}] \\ = \int_{\mathbb{R}^{d_2}} \log(f(x^m | x, p^{old})) f(x^m | x, p^{old}) dx^m - \int_{\mathbb{R}^{d_2}} \log(f(x^m | x, p)) f(x^m | x, p^{old}) dx^m \\ = \int_{\mathbb{R}^{d_2}} \log \left( \frac{f(x^m | x, p^{old})}{f(x^m | x, p)} \right) f(x^m | x, p^{old}) dx^m \\ = - \int_{\mathbb{R}^{d_2}} \log \left( \frac{f(x^m | x, p)}{f(x^m | x, p^{old})} \right) f(x^m | x, p^{old}) dx^m \end{aligned}$$

De plus,  $x \mapsto \log(x)$  est strictement concave, donc par l'inégalité de Jensen :

$$\int_{\mathbb{R}^{d_2}} \log \left( \frac{f(x^m | x, p)}{f(x^m | x, p^{old})} \right) f(x^m | x, p^{old}) dx^m \geq \log \left( \int_{\mathbb{R}^{d_2}} \frac{f(x^m | x, p)}{f(x^m | x, p^{old})} f(x^m | x, p^{old}) dx^m \right) = \log(1) = 0$$

### Question 2.1

**Montrons que pour tout  $s, t > 0$ ,**  $\mathbb{P}(T > s + t | T > t) = \mathbb{P}(T > s)$ .

Soient  $s, t > 0$  et  $T \sim \exp(a)$ .

$$\mathbb{P}(T > s + t | T > t) = \frac{\mathbb{P}(T > s + t, T > t)}{\mathbb{P}(T > t)} = \frac{\mathbb{P}(T > s + t)}{\mathbb{P}(T > t)} = \frac{e^{-(s+t)a}}{e^{-ta}} = e^{-as} = \mathbb{P}(T > s)$$

Donc T est une variable aléatoire « avec perte de mémoire ».

### Question 2.2

**Montrons que**  $Q(a, a^{old}) = N \log(a) - a \left[ \sum_{i=1}^k t_i + (N - k) \left( C + \frac{1}{a^{old}} \right) \right]$

$$\begin{aligned} \mathbb{E}[\log f(T^c, a) | t_1, \dots, t_k, t_{k+1} \geq C, \dots, t_N \geq C, a^{old}] &= \int_{\mathbb{R}^{d_2}} \log \left( \prod_{i=1}^N a e^{-at_i} \right) f(t^m | t, a^{old}) dt^m \\ &= \int_{\mathbb{R}^{d_2}} \sum_{i=1}^N (\log(a) - at_i) f(t^m | t, a^{old}) dt^m \\ &= N \log(a) \int_{\mathbb{R}^{d_2}} f(t^m | t, a^{old}) dt^m - a \int_{\mathbb{R}^{d_2}} \sum_{i=1}^N t_i f(t^m | t, a^{old}) dt^m \\ &= N \log(a) - a \left( \sum_{i=1}^k t_i \int_{\mathbb{R}^{d_2}} f(t^m | t, a^{old}) dt^m + \int_{\mathbb{R}^{d_2}} \sum_{t=k+1}^N t_i f(t^m | t, a^{old}) dt^m \right) \\ &= N \log(a) - a \left( \sum_{i=1}^k t_i + \int_{\mathbb{R}^{d_2}} \sum_{t=k+1}^N t_i f(t^m | t, a^{old}) dt^m \right) \end{aligned}$$

$$\text{Or } f(t^m | t, a^{old}) = \frac{f((t, t^m), a^{old})}{f_T(t, a^{old})} = \frac{a^{old} e^{-a^{old}(t+t^m)}}{\int_{\mathbb{R}^{d_2}} a^{old} e^{-a^{old}(t+t^m)} dt^m} = a^{old} e^{-a^{old} t^m}$$

$$\begin{aligned} \text{Donc } \int_{\mathbb{R}^{d_2}} \sum_{t=k+1}^N t_i f(t^m | t, a^{old}) dt^m &= \int_{\mathbb{R}^{d_2}} \sum_{t=k+1}^N t_i a^{old} e^{-a^{old} t^m} dt^m \\ &= \int_{\mathbb{R}^{d_2}} \sum_{t=k+1}^N t_i a^{old} e^{-a^{old} \sum_{i=k+1}^N t_i} dt^m = E[T^m | T = t, a^{old}] \end{aligned}$$

On a  $t_{k+1}, \dots, t_N \geq C$  et l'espérance d'une loi exponentielle de paramètre  $a^{old}$  vaut  $\frac{1}{a^{old}}$

$$\Rightarrow E[t_i | T = t, a^{old}] = \left( C + \frac{1}{a^{old}} \right) \text{ pour tout } i = k+1, \dots, N$$

$$\Rightarrow E[T^m | T = t, a^{old}] = (N - k) \left( C + \frac{1}{a^{old}} \right)$$

Et donc on a bien :

$$\begin{aligned} Q(a, a^{old}) &= E[\log f(T^c, a) | t_1, \dots, t_k, t_{k+1} \geq C, \dots, t_N \geq C, a^{old}] \\ &= N \log(a) - a \left[ \sum_{i=1}^k t_i + (N - k) \left( C + \frac{1}{a^{old}} \right) \right] \end{aligned}$$

**En déduire que si  $a^{new}$  maximise  $a \mapsto Q(a, a^{old})$  alors  $a^{new} = \frac{N}{\sum_{i=1}^k t_i + (N-k) \left( C + \frac{1}{a^{old}} \right)}$**

$$\frac{\partial Q(a, a^{old})}{\partial a} = \frac{N}{a} - \left( \sum_{i=1}^k t_i + (N - k) \left( C + \frac{1}{a^{old}} \right) \right)$$

$$\frac{\partial Q(a, a^{old})}{\partial a} = 0 \Leftrightarrow \frac{N}{a} = \left( \sum_{i=1}^k t_i + (N - k) \left( C + \frac{1}{a^{old}} \right) \right) \Leftrightarrow a^{new} = \frac{N}{\sum_{i=1}^k t_i + (N-k) \left( C + \frac{1}{a^{old}} \right)}$$

$$\frac{\partial^2 Q(a, a^{old})}{\partial a^2} = -\frac{N}{a^2} < 0. \text{ Donc } a^{new} = \frac{N}{\sum_{i=1}^k t_i + (N-k) \left( C + \frac{1}{a^{old}} \right)} \text{ maximise } a \mapsto Q(a, a^{old}).$$

**En déduire que l'algo EM converge vers  $\hat{a} = \frac{k}{\sum_{i=1}^k t_i + (N-k)C}$**

$$a^{new} = \frac{N}{\sum_{i=1}^k t_i + (N - k) \left( C + \frac{1}{a^{old}} \right)}$$

Si l'algorithme converge vers une limite  $\hat{a}$  alors  $a^{old} \rightarrow \hat{a}$  et  $a^{new} \rightarrow \hat{a}$ , on a donc :

$$\begin{aligned} a^{new} \rightarrow \hat{a} &= \frac{N}{\sum_{i=1}^k t_i + (N-k) \left( C + \frac{1}{\hat{a}} \right)} \Leftrightarrow \hat{a} \left( \sum_{i=1}^k t_i + (N - k) \left( C + \frac{1}{\hat{a}} \right) \right) = N \\ &\Leftrightarrow \hat{a} \sum_{i=1}^k t_i + \hat{a} (N - k) C + N - k = N \\ &\Leftrightarrow \hat{a} \left( \sum_{i=1}^k t_i + (N - k) C \right) = N - N + k \\ &\Leftrightarrow \hat{a} = \frac{k}{\sum_{i=1}^k t_i + (N - k) C} \end{aligned}$$

Donc si l'algorithme EM converge, il converge vers  $\hat{a} = \frac{k}{\sum_{i=1}^k t_i + (N - k) C}$

**Montrons que  $\hat{a}$  est l'EMV d'une expérience où les données observées sont N variables aléatoires i.i.d  $X_1, \dots, X_N$  distribuées comme  $X = T \mathbb{I}_{(T \leq C)} + C \mathbb{I}_{(T > C)}$  et  $k = |\{i: T_i \leq C\}|$ .**

$$\begin{aligned}\mathbb{P}(X \leq x) &= \mathbb{P}(T\mathbb{I}_{(T \leq C)} + C\mathbb{I}_{(T > C)} \leq x) = \mathbb{P}(T \leq x, T \leq C) + \mathbb{P}(C \leq x, T > C) \\ &= \begin{cases} \mathbb{P}(T \leq x, T \leq C) & \text{pour tout } T \in \{t_1, \dots, t_k\} \\ \mathbb{P}(C \leq x, T > C) & \text{pour tout } T \in \{t_{k+1}, \dots, t_N\} \end{cases}\end{aligned}$$

$$\mathbb{P}(T \leq x, T \leq C) = \mathbb{P}(T \leq x) \text{ car } X = T\mathbb{I}_{(T \leq C)} + C\mathbb{I}_{(T > C)} \leq C \quad \forall T$$

$$\mathbb{P}(C \leq x) = \begin{cases} 1 & \text{si } C \leq x \\ 0 & \text{si } C > x \end{cases} \text{ donc :}$$

$$\begin{aligned}\mathbb{P}(C \leq x, T > C) &= \mathbb{P}(T > C)\mathbb{P}(C \leq x) = \mathbb{P}(T > C)\mathbb{I}_{(C \leq x)} = (1 - \mathbb{P}(T \leq C))\mathbb{I}_{(C \leq x)} = \\ &= (1 - (1 - e^{-ac}))\mathbb{I}_{(C \leq x)} = e^{-ac}\mathbb{I}_{(C \leq x)}\end{aligned}$$

Finalement :

$$\mathbb{P}(X \leq x) = \begin{cases} \mathbb{P}(T \leq x) & T \in \{t_1, \dots, t_k\} \\ e^{-ac}\mathbb{I}_{(C \leq x)} & T \in \{t_{k+1}, \dots, t_N\} \end{cases} = \begin{cases} 1 - e^{-ax} & T \in \{t_1, \dots, t_k\} \\ e^{-ac}\mathbb{I}_{(C \leq x)} & T \in \{t_{k+1}, \dots, t_N\} \end{cases}$$

Donc la vraisemblance est donnée par :

$$\prod_{i=1}^N \left( ae^{-at_i}\mathbb{I}_{(0 \leq x_i < C)} + e^{-ac}\mathbb{I}_{(C \leq x_i)} \right) \quad \text{où } f_T(t_i) = ae^{-at_i} \mathbb{I}_{(t_i \geq 0)} \text{ et } \mathbb{P}(T > C)\mathbb{I}_{(C \leq x_i)} = e^{-ac}\mathbb{I}_{(C \leq x_i)}$$

$$\prod_{i=1}^N \left( ae^{-at_i}\mathbb{I}_{(0 \leq x_i < C)} + e^{-ac}\mathbb{I}_{(C \leq x_i)} \right) = a^k e^{-a \sum_{i=1}^k x_i} e^{-ac(N-k)} \text{ car } k = |\{i: T_i \leq C\}|$$


$$\mathcal{L}(a) = k \log(a) - a \sum_{i=1}^k t_i - ac(N-k)$$

$$\mathcal{L}'(a) = \frac{k}{a} - \sum_{i=1}^k t_i - C(N-k)$$

$$\mathcal{L}'(a) = 0 \Leftrightarrow \frac{k}{a} - \sum_{i=1}^k t_i - C(N-k) = 0 \Leftrightarrow \frac{k}{a} = \sum_{i=1}^k t_i + C(N-k) \Leftrightarrow \hat{a} = \frac{k}{\sum_{i=1}^k t_i + C(N-k)}$$

### Question 2.3

**Montrons la convergence de l'algo EM et estimons la vitesse de convergence en fonction du nombre d'itérations.**



```

### mise en place des variables
a<-0.5
N<-10000 #Nombre d'observations
C<-5 #seuil

### mise en place des conditions de convergence (nb d'itération et tolérance)
a_new<-0.1
iter<-0
err<-1 #erreur
err_vect=NULL
tol<-0.00000001

### Algorithme EM

t<-rexp(N,a) ###simulation de N variables de loi exp(a)
t<-sort(t)
K=t<C #mesure de comptage, nombre d'éléments de t<C
t<-t[K] #on prend les k premiers éléments du vecteur t
k<-length(t)
a_chapeau<-k/(sum(t)+(N-k)*C) ###Valeur de convergence théorique


while (iter<100000 && err>tol){
  a_new<-N/(sum(t)+(N-k)*(C+1/a_new))
  err<-abs(a_new-a_chapeau)
  err_vect<-c(err_vect,log(err))
  iter<-iter+1
}

iter
err
a
a_chapeau
a_new
plot(err_vect)

```

### Question 3.1

Représenter graphiquement un mélange de 10 gaussiennes dans  $\mathbb{R}^2$



code sur R pour obtenir le graphe ci-dessus :

```

N<-5000 #nombre de données connues
k<-10 #nombre de loi gaussienne
X<-matrix(ncol = 3,nrow=N)
couleur = palette (rainbow(10))

ALPHA<-c(0.1,0.1,0.1,0.1,0.1,0.1,0.1,0.1,0.1,0.1)
mu1<-c(0,10,4,13,8,2,12,15,2,16)
mu2<-c(0,13,10.3,1,8,6,7,2,4.5,10)

sigma<-c(0.75,0.5,0.75,1,0.86,0.6,0.4,1,0.75,0.625)

for(i in 1:N){
  j<-rbinom(1,k-1,0.5) #Tirage des loi normales selon une loi
  binomiale
  X[i,1]<-rnorm(1,mu1[j+1],sigma[j+1])
  X[i,2]<-rnorm(1,mu2[j+1],sigma[j+1])
  X[i,3]<-j+1
}

plot(X[,1],X[,2], col=couleur[X[,3]])

```

### Question 3.2

Montrons que  $Q(p, p^{old}) = \sum_{n=1}^N \sum_{k=1}^K f(k|x_n, p^{old}) \log \alpha_k + \sum_{n=1}^N \sum_{k=1}^K f(k|x_n, p^{old}) \log f_k(x_n, p_k)$

$$\begin{aligned}
 Q(p, p^{old}) &= \mathbb{E}[\log f(X^c, p) | X = x, p^{old}] = \sum_{k=1}^K f(k|x, p^{old}) \log (f(x^c, p)) \\
 &= \sum_{n=1}^N \sum_{k=1}^K f(k|x_n, p^{old}) (\log(\alpha_k) + \log f_k(x_n, p_k)) \\
 &= \sum_{n=1}^N \sum_{k=1}^K f(k|x_n, p^{old}) \log(\alpha_k) + \sum_{n=1}^N \sum_{k=1}^K f(k|x_n, p^{old}) \log f_k(x_n, p_k)
 \end{aligned}$$

### Question 3.3

On veut résoudre le problème d'optimisation suivant :

$\operatorname{argmax}_{\alpha_1, \dots, \alpha_K} Q(p, p^{old})$  sous la contrainte  $\sum_{k=1}^K \alpha_k = 1$

On va utiliser la méthode des multiplicateurs de Lagrange.

$$L(\alpha, \lambda) = Q(p, p^{old}) - \lambda(\sum_{k=1}^K \alpha_k - 1)$$

On annule la dérivée partielle de  $\alpha, \lambda$ .

$$\begin{aligned} \frac{dL(\alpha, \lambda)}{\partial \alpha_k} = 0 &\Leftrightarrow \frac{dL(\alpha, \lambda)}{\partial \alpha_k} = \sum_{n=1}^N \frac{f(k|x_n, p^{old})}{\alpha_k} - \lambda = 0 &\Leftrightarrow \alpha_k = \frac{1}{\lambda} \sum_{n=1}^N f(k|x_n, p^{old}) \\ \frac{dL(\alpha, \lambda)}{\partial \lambda} = 0 &\Leftrightarrow \frac{dL(\alpha, \lambda)}{\partial \lambda} = \sum_{n=1}^N \alpha_k - 1 = 0 &\Leftrightarrow \sum_{k=1}^K \alpha_k = 1 \end{aligned}$$

Comme  $\sum_{k=1}^K \alpha_k = 1$  et  $\alpha_k = \frac{1}{\lambda} \sum_{n=1}^N f(k|x_n, p^{old})$  alors  $\sum_{k=1}^K \alpha_k = \sum_{k=1}^K \frac{1}{\lambda} \sum_{n=1}^N f(k|x_n, p^{old}) = 1$   
 $\Leftrightarrow \lambda = \sum_{n=1}^N \sum_{k=1}^K f(k|x_n, p^{old})$  or  $\sum_{k=1}^K f(k|x_n, p^{old}) = 1$  car  $f(k|x_n, p^{old})$  est une densité.  
 $\Leftrightarrow \lambda = \sum_{n=1}^N 1 = N$

Donc on a bien  $\alpha_k = \frac{1}{N} \sum_{n=1}^N f(k|x_n, p^{old})$

Vérifions que  $\alpha_k$  est un maximum :

$$\frac{d^2 L(\alpha, \lambda)}{d\alpha_k^2} = \sum_{n=1}^N \left( -\frac{f(k|x_n, p^{old})}{\alpha_k^2} \right) \leq 0 \quad \text{Donc } L(\alpha, \lambda) \text{ est concave et } \alpha_k \text{ est bien un maximum.}$$

### Question 3.4

$$\text{Montrons que } f(k|x_n, p^{old}) = \frac{\frac{\alpha_k^{old}}{\sigma_k^{old}} \exp\left(-(x_n - \mu_k^{old})^2 / (2(\sigma_k^{old})^2)\right)}{\sum_{k=1}^K \frac{\alpha_k^{old}}{\sigma_k^{old}} \exp\left(-(x_n - \mu_k^{old})^2 / (2(\sigma_k^{old})^2)\right)}$$

$$\begin{aligned} f(k|x_n, p^{old}) &= \frac{f(k, x_n, p^{old})}{f(x_n, p^{old})} = \frac{f(k) f(x_n, p^{old}|k)}{f(x_n, p^{old})} = \frac{f(k) f_k(x_n, p^{old})}{\sum_{k=1}^K \alpha_k^{old} f_k(x_n, p^{old})} = \frac{\frac{\alpha_k^{old}}{\sqrt{2\pi} \sigma_k^{old}} \exp\left(-(x_n - \mu_k^{old})^2 / (2(\sigma_k^{old})^2)\right)}{\sum_{k=1}^K \frac{\alpha_k^{old}}{\sigma_k^{old}} \exp\left(-(x_n - \mu_k^{old})^2 / (2(\sigma_k^{old})^2)\right)} \\ &= \frac{\frac{\alpha_k^{old}}{\sigma_k^{old}} \exp\left(-(x_n - \mu_k^{old})^2 / (2(\sigma_k^{old})^2)\right)}{\sum_{k=1}^K \frac{\alpha_k^{old}}{\sigma_k^{old}} \exp\left(-(x_n - \mu_k^{old})^2 / (2(\sigma_k^{old})^2)\right)} \end{aligned}$$

$$\text{Montrons que } \mu_k^{new} = \frac{\sum_{n=1}^N x_n f(k|x_n, p^{old})}{\sum_{n=1}^N f(k|x_n, p^{old})}$$

Pour cela nous allons dériver  $Q(p, p^{old})$

$f(k|x_n, p^{old})$  et  $\alpha_k$  sont des constantes vu qu'on connaît déjà  $p^{old}$ . On calcule la dérivée partielle de  $\log(f_k(x_n, p_k))$ .

$$\begin{aligned} \frac{df_k(x_n, p^{old})}{d\mu_k} &= \frac{1}{\sqrt{2\pi} \sigma_k^{old}} \frac{(x_n - \mu_k^{old})}{2(\sigma_k^{old})^2} \exp\left(-\frac{(x_n - \mu_k^{old})^2}{2(\sigma_k^{old})^2}\right) = f_k(x_n, p^{old}) \frac{(x_n - \mu_k^{old})}{2(\sigma_k^{old})^2} \\ \frac{d\log(f_k(x_n, p^{old}))}{d\mu_k} &= \frac{f_k(x_n, p^{old}) \frac{(x_n - \mu_k^{old})}{2(\sigma_k^{old})^2}}{f_k(x_n, p^{old})} = \frac{(x_n - \mu_k^{old})}{2(\sigma_k^{old})^2} \end{aligned}$$

Posons  $A = \sum_{k=1}^K f(k|x_n, p^{old}) \log(\alpha_k)$  et  $B = \sum_{k=1}^K f(k|x_n, p^{old}) \log(f_k(x_n, p_k))$

$$\frac{dA}{d\mu_k} = 0$$

$$\frac{dB}{d\mu_k} = f(k|x_n, p^{old}) \frac{d\log(f_k(x_n, p_k))}{d\mu_k} = f(k|x_n, p^{old}) \frac{(x_n - \mu_k^{old})}{2(\sigma_k^{old})^2}$$



$$\frac{dQ(p, p^{old})}{d\mu_k} = \sum_{n=1}^N \frac{dA}{d\mu_k} + \frac{dB}{d\mu_k} = \sum_{n=1}^N f(k|x_n, p^{old}) \frac{(x_n - \mu_k^{old})}{2(\sigma_k^{old})^2}$$

$$\begin{aligned} \frac{dQ(p, p^{old})}{d\mu_k} = 0 & \Leftrightarrow \sum_{n=1}^N f(k|x_n, p^{old}) (x_n - \mu_k^{new}) = 0 \\ & \Leftrightarrow \mu_k^{new} = \frac{\sum_{n=1}^N x_n f(k|x_n, p^{old})}{\sum_{n=1}^N f(k|x_n, p^{old})} \end{aligned}$$

Vérifions que  $\mu_k$  est un maximum :

$\frac{d^2 Q(p, p^{old})}{d\mu_k^2} = \sum_{n=1}^N f(k|x_n, p^{old}) \frac{-1}{2(\sigma_k^{old})^2}$  or  $f(k|x_n, p^{old}) \frac{-1}{2(\sigma_k^{old})^2} < 0$  Donc  $Q(p, p^{old})$  est concave et  $\mu_k$  est bien un maximum.

**Démontrons**  $(\sigma_k^{new})^2 = \frac{\sum_{n=1}^N (x_n - \mu_k^{new})^2 f(k|x_n, p^{old})}{\sum_{n=1}^N f(k|x_n, p^{old})}$

Calculons la dérivée partielle de  $\log(f_k(x_n, p_k))$ :

$$\begin{aligned} \frac{df_k(x_n, p_k)}{d\sigma_k} &= \frac{-1}{\sqrt{2\pi}(\sigma_k^{old})^2} \exp\left(-\frac{(x_n - \mu_k^{new})^2}{2(\sigma_k^{old})^2}\right) + \frac{1}{\sqrt{2\pi}(\sigma_k^{old})} \frac{(x_n - \mu_k^{new})^2}{2(\sigma_k^{old})^4} 2\sigma_k^{old} \exp\left(-\frac{(x_n - \mu_k^{new})^2}{2(\sigma_k^{old})^2}\right) \\ &= f_k(x_n, p^{old}) \left(-\frac{1}{\sigma_k^{old}} + \frac{(x_n - \mu_k^{new})^2}{(\sigma_k^{old})^3}\right) \\ \frac{d\log(f_k(x_n, p^{old}))}{d\sigma_k} &= \frac{f_k(x_n, p^{old}) \left(-\frac{1}{\sigma_k^{old}} + \frac{(x_n - \mu_k^{new})^2}{(\sigma_k^{old})^3}\right)}{f_k(x_n, p^{old})} = \left(-\frac{1}{\sigma_k^{old}} + \frac{(x_n - \mu_k^{new})^2}{(\sigma_k^{old})^3}\right) \end{aligned}$$

Calculons  $\frac{dA}{d\sigma_k}$  et  $\frac{dB}{d\sigma_k}$ :

$$\begin{aligned} \frac{dA}{d\sigma_k} &= 0 \\ \frac{dB}{d\sigma_k} &= f(k|x_n, p^{old}) \frac{d\log(f_k(x_n, p_k))}{d\sigma_k} = f(k|x_n, p^{old}) \left(-\frac{1}{\sigma_k^{old}} + \frac{(x_n - \mu_k^{new})^2}{(\sigma_k^{old})^3}\right) \end{aligned}$$

$$\frac{dQ(p, p^{old})}{d\sigma_k} = \sum_{n=1}^N \frac{dA}{d\sigma_k} + \frac{dB}{d\sigma_k} = \sum_{n=1}^N f(k|x_n, p^{old}) \left(-\frac{1}{\sigma_k^{old}} + \frac{(x_n - \mu_k^{new})^2}{(\sigma_k^{old})^3}\right)$$

$$\begin{aligned} \frac{dQ(p, p^{old})}{d\sigma_k} = 0 & \Leftrightarrow \sum_{n=1}^N f(k|x_n, p^{old}) \left(-\frac{1}{\sigma_k^{new}} + \frac{(x_n - \mu_k^{new})^2}{(\sigma_k^{new})^3}\right) = 0 \\ & \Leftrightarrow \sum_{n=1}^N f(k|x_n, p^{old}) \frac{1}{\sigma_k^{new}} = \sum_{n=1}^N f(k|x_n, p^{old}) \frac{(x_n - \mu_k^{new})^2}{(\sigma_k^{new})^3} \\ & \Leftrightarrow \frac{(\sigma_k^{new})^3}{\sigma_k^{new}} = \frac{\sum_{n=1}^N (x_n - \mu_k^{new})^2 f(k|x_n, p^{old})}{\sum_{n=1}^N f(k|x_n, p^{old})} \\ & \Leftrightarrow (\sigma_k^{new})^2 = \frac{\sum_{n=1}^N (x_n - \mu_k^{new})^2 f(k|x_n, p^{old})}{\sum_{n=1}^N f(k|x_n, p^{old})} \end{aligned}$$

### Question 3.5

**Proposer un algorithme de « Clustering »**